1. Improving Language Understanding by Generative Pre-Training

1.1 연구 배경

자연어 처리(NLP) 분야의 대부분의 모델은 지도학습 기반으로 학습되어 왔다. 이러한 방식은 특정 작업을 수행하기 위해 대량의 라벨링 데이터가 필요하다는 한계를 가진다. 실제로 자연어 추론, 질의응답, 문서 분류 등의 다양한 자연어 이해 작업에서는 충분한 라벨 데이터 확보가 어렵다.

이에 따라 라벨이 없는 대규모 텍스트 데이터를 활용하여 모델을 사전 학습한 후, 특정 작업에 맞게 미세 조정하는 방법이 제안되었다. 이 논문은 이러한 접근을 체계적으로 제시하며, 대규모 비지도 학습을 통해 범용 언어 표현을 학습하고 이를 다양한 자연어 이해 작업에 활용할 수 있음을 보여준다.

1.2 연구 목적

본 연구의 목적은 다음과 같다.

대규모 비지도 텍스트 데이터를 활용하여 범용적인 언어 표현을 학습한다.

사전 학습된 모델을 다양한 자연어 이해 작업에 적용할 수 있는 구조를 설계한다.

기존의 작업별 모델 설계 방식보다 일반화 성능이 높은 모델을 제시한다.

1.3 모델 구조

논문에서는 Transformer 기반의 언어 모델을 사용한다. 모델은 Transformer의 디코더 구조를 기반으로 하며 다음과 같은 구성으로 이루어진다.

- Token Embedding
- Position Embedding
- Multi-Head Self-Attention
- Feed Forward Network
- Softmax 출력층

이 구조는 문장 내 단어 간의 장기 의존성을 효과적으로 학습할 수 있으며, 기존의 RNN이나 LSTM 기반 모델보다 긴 문맥 정보를 잘 처리할 수 있다.

1.4 학습 방법

1) 사전 학습 (Pre-training)

사전 학습 단계에서는 언어 모델링(Language Modeling) 목표 함수를 사용한다.

$$L_1(U) = \sum logP(u_i|u_{i-k}, ..., u_{i-1})$$

이는 이전 단어들을 기반으로 다음 단어의 확률을 예측하도록 학습하는 방식이다. 이를 통해 모델은 문법적 구조와 의미적 관계를 학습하게 된다.

2) 미세 조정 (Fine-tuning)

사전 학습된 모델을 특정 작업에 맞게 학습시키는 과정이다.

$$P(y|x_1, ..., x_m) = softmax(h_m^l W_y)$$

Transformer의 마지막 출력 벡터를 선형 분류기에 입력하여 작업별 결과를 예측한다.

1.5 입력 변환 방식

논문에서는 다양한 자연어 작업을 하나의 모델로 처리하기 위해 입력 구조를 토큰 시퀀스로 변환한다.

- 문장 분류

  [Start] 문장

- 자연어 추론

  [Start] premise $ hypothesis

- 질의응답

  document + question + answer candidate

이 방식은 작업마다 별도의 모델 구조를 설계하지 않고도 동일한 모델을 사용할 수 있게 한다.

1.6 실험 결과

모델은 자연어 추론, 질의응답, 문장 유사도, 문서 분류 등의 다양한 작업에서 평가되었다.

대표적인 성능 향상 결과는 다음과 같다.

Commonsense reasoning: 8.9% 향상

Question answering: 5.7% 향상

Textual entailment: 1.5% 향상

총 12개 작업 중 9개에서 기존 최고 성능을 능가하였다.

1.7 연구 의의

이 논문은 이후 등장하는 대규모 언어 모델의 기본 패러다임을 제시하였다.

주요 의의는 다음과 같다.

Pretrain + Finetune 구조 제시

Transformer 기반 언어 모델의 가능성 입증

하나의 모델로 여러 NLP 작업을 수행하는 범용 모델 구조 제안

이 접근은 이후 GPT-2, GPT-3 등 현대 대규모 언어 모델의 기반이 되었다.

2. DeepSeek-R1: Reinforcement Learning을 통한 추론 능력 향상

2.1 연구 배경

최근 대규모 언어 모델은 다양한 자연어 작업에서 높은 성능을 보이지만 복잡한 추론 문제에서는 여전히 한계를 가진다. 이를 해결하기 위해 Chain-of-Thought prompting이나 인간이 작성한 추론 데이터로 학습하는 방법이 사용되어 왔다.

그러나 이러한 방법은 다음과 같은 문제를 가진다.

- 인간이 작성한 추론 데이터에 의존
- 확장성 부족
- 인간 사고 방식에 제한됨

따라서 본 논문은 강화학습을 이용하여 모델이 스스로 추론 능력을 학습하도록 하는 방법을 제안한다.

2.2 연구 목적

본 연구의 목표는 다음과 같다.

1. 인간이 작성한 추론 데이터 없이도 모델이 추론 능력을 학습하도록 한다.
2. 강화학습을 활용하여 모델이 스스로 문제 해결 전략을 발견하도록 한다.
3. 수학, 코드, 과학 문제 등 복잡한 reasoning task에서 성능을 향상시킨다.

2.3 DeepSeek-R1-Zero

연구의 첫 번째 단계는 DeepSeek-R1-Zero 모델이다.

특징

- Supervised Fine-Tuning 없이 학습
- Reinforcement Learning만 사용
- reasoning 능력의 자연적 emergence 관찰

모델은 문제에 대해 여러 답변을 생성하고 정답 여부에 따라 보상을 받는다.

2.4 강화학습 알고리즘

논문에서는 GRPO(Group Relative Policy Optimization) 알고리즘을 사용한다.

GRPO는 PPO 기반 알고리즘을 개선한 것으로 다음과 같은 특징을 가진다.

- 여러 개의 답을 동시에 생성
- 그룹 내 결과를 비교하여 advantage 계산
- 학습 안정성 및 효율성 향상

이를 통해 모델은 더 좋은 답변을 생성하는 방향으로 학습된다.

2.5 보상 설계

강화학습에서 중요한 요소는 보상 함수이다.

논문에서는 다음 두 가지 보상을 사용한다.

1. 정확도 보상

답이 정확한 경우 보상을 부여한다.

예시

- 수학 문제 정답 여부
- 코드 테스트 통과 여부

---

2. 형식 보상

모델이 reasoning 과정을 명확하게 출력하도록 유도한다.

출력 형식

```
<think> reasoning </think>
<answer> final answer </answer>
```

이를 통해 모델의 사고 과정을 분석할 수 있다.

2.6 추론 능력의 Emergence

강화학습 과정에서 모델은 다음과 같은 행동을 자연스럽게 학습하였다.

- 자기 검증 (self-verification)
- 해결 전략 수정
- 여러 해결 방법 탐색

논문에서는 이를 self-evolution이라고 설명한다.

또한 학습 과정에서 모델이 스스로 "wait, let's reconsider"와 같은 재검토 행동을 보이는 현상이 관찰되었다.

2.7 DeepSeek-R1 최종 모델

R1-Zero는 강한 추론 능력을 보였지만 다음과 같은 문제점이 있었다.

- 가독성 부족
- 언어 혼합 문제
- 일반 대화 성능 부족

이를 해결하기 위해 다음과 같은 다단계 학습 구조가 사용되었다.

학습 과정

Base Model

→ Reinforcement Learning

→ Rejection Sampling

→ Supervised Fine-Tuning

→ Reinforcement Learning (Alignment)

이를 통해 reasoning 능력과 일반 언어 능력을 동시에 향상시켰다.

2.8 성능 평가

모델은 다양한 벤치마크에서 평가되었다.

대표적인 결과

- MMLU: 90.8
- Codeforces: 상위 96 percentile
- AIME 수학 문제: 79.8

특히 수학, 코드, 과학 문제에서 높은 성능을 보였다.

2.9 연구 의의

DeepSeek-R1 논문은 다음과 같은 의미를 가진다.

1. 강화학습만으로 추론 능력을 학습할 수 있음을 보여줌
2. 인간 reasoning 데이터 의존도를 줄임
3. LLM reasoning 연구의 새로운 패러다임 제시