**Transformer**

## 1. 트랜스포머 개요

트랜스포머(Transformer)는 순환(RNN)이나 합성곱(CNN)을 사용하지 않고,

어텐션(Attention)만으로 시퀀스를 처리하는 신경망 구조다.

자연어 처리(NLP)를 중심으로 번역, 요약, 질의응답 등에서 기존 모델을 압도했다.

핵심은 모든 토큰을 동시에 보고 중요한 관계에 가중치를 부여하는 것이다.

## 2. 기존 모델의 한계

RNN / LSTM

시퀀스를 순차적으로 처리 -> 병렬화 불가능

장기 의존성 문제(먼 과거 정보 소실)

Seq2Seq

이전 토큰을 입력으로 받으며 순차적으로 단어를 생성하는 구조

하지만 Transformer는 Self-Attention을 통해 전체 시퀀스를 병렬적으로 처리

### 3.1 Self-Attention

각 토큰이 문장 내 모든 토큰을 직접 참조해 중요도를 계산한다.

Query(Q), Key(K), Value(V) 벡터 사용

특정 단어가 다른 단어와 얼마나 관련 있는지 점수화

거리와 무관하게 전역 의존성 학습 가능

### 3.2 Multi-Head Attention

Self-Attention을 여러 개 병렬로 수행한다.

각 헤드는 다른 관점의 관계 학습

문법적 관계, 의미적 관계 등을 동시에 포착

### 3.3 Positional Encoding

트랜스포머는 순서를 직접 처리하지 않기 때문에

위치 정보(Positional Encoding)를 입력 임베딩에 추가한다.

사인, 코사인 기반 고정 방식 또는 학습 방식

이 단어가 몇 번째인가에 대한 정보를 제공

### 3.4 Encoder–Decoder 구조

Encoder

입력 문장 이해

(Self-Attention → FFN) 반복

Decoder

출력 문장 생성

Masked Self-Attention + Encoder–Decoder Attention 사용

**BERT**

## 1. BERT 개요

BERT (Bidirectional Encoder Representations from Transformers)는

Transformer Encoder만을 사용해 문맥을 양방향(bidirectional)으로 이해하는 사전 학습 언어모델이다. 기존 언어모델이 한쪽 방향 문맥만 보던 한계를 해결했다.

핵심은 문장을 생성하는 모델이 아니라, 문장을 정확히 이해하는 모델이다.

## 2. 기존 모델의 한계

GPT 계열(초기): 왼쪽 → 오른쪽 단방향

과거 토큰만 보고 현재 단어 예측

문장 전체 의미 이해에 한계

-> BERT는 앞, 뒤 문맥을 동시에 사용해 단어 의미를 학습한다.

### 3.1 Transformer Encoder 기반

Multi-Head Self-Attention

모든 토큰이 서로 직접 참조

출력은 각 토큰의 문맥 임베딩

### 3.2 입력 표현 방식

BERT 입력은 3가지 임베딩의 합으로 구성된다.

Token Embedding: 단어 토큰

Segment Embedding: 문장 A/B 구분

Position Embedding: 위치 정보

[CLS] : 문장 전체 대표 벡터

[SEP] : 문장 구분

**4.1 MLM (Masked Language Model)**

문장 중 일부 단어를 [MASK]로 가림

앞·뒤 문맥을 보고 원래 단어 예측

**4.2 NSP (Next Sentence Prediction)**

두 문장이 연속된 문장인지 분류

문장 간 관계 학습 (QA, NLI에 중요)

**5. Fine-tuning 방식**

BERT는 하나의 사전학습 모델을

작은 출력층만 추가해 다양한 태스크에 적용한다.

문장 분류 → [CLS] 벡터 사용

토큰 분류(NER) → 토큰별 출력 사용

QA → 시작/끝 위치 예측